Przedmiot:	Informatyka
Temat sprawozdania:	Automatyzacja audytu dokumentów prawnych przy użyciu metod przetwarzania języka naturalnego (NLP)
Imię i nazwisko:	Emiliya Harbatsiuk
Data:	01.06.2026

SPIS TREŚCI

1. Wstęp 3
1.1. Cel projektu 3
1.2. Motywacja 3
2. Podstawy Teoretyczne 3
2.1. Metody NLP 3
2.2. Koncepcja Pattern Matching 3
2.3. Specyfika języka polskiego 3
3. Opis środowiska i bibliotek 4
3.1. Środowisko Microsoft Visual Studio 2022 4
3.2. Wykorzystane biblioteki 4
4. Architektura systemu 4
4.1. Struktura plików projektu 4
4.2. Opis modułów 4
5. Prezentacja Wyników i Analiza Dashboardu 5
5.1. Graficzny interfejs użytkownika (UI/UX) 5
5.2. Wyjaśnienie kluczowych fragmentów kodu 7
6. Analiza przypadków szczególnych (Walidacja na plikach PDF) 8
6.1. Przypadek 1: Umowa Najmu Lokalu 8
6.2. Przypadek 2: Kontrakt B2B dla IT-Specjalisty 8
7. Wyzwania i Ograniczenia 9
8. Możliwe kierunki rozwoju systemu 10
9. Wnioski biznesowe 10
10. Podsumowanie 10
11. Załączniki 11

1. Wstęp

1.1. Cel projektu

Celem projektu było zaimplementowanie modułowej aplikacji webowej do automatycznego audytu i analizy ryzyka w polskich umowach cywilnoprawnych w formacie PDF.

Cele szczegółowe:

- Stworzenie interfejsu (Dashboardu) w architekturze klient-serwer.
- Ekstrakcja tekstu PDF z zachowaniem informacji o numerach stron.
- Identyfikacja sygnatariuszy (NER) oraz ram czasowych umowy za pomocą RegEx.
- Obliczenie wskaźnika *Safety Score* i wizualizacja statystyk ryzyk.

1.2. Motywacja

Konsumenci i przedsiębiorcy często podpisują umowy zawierające ukryte klauzule abuzywne (asymetryczne kary, jednostronne zmiany warunków, natychmiastowe zerwanie współpracy). Manualna weryfikacja dokumentów jest czasochłonna i podatna на błędy ludzkie. Zautomatyzowanie tego procesu za pomocą metod NLP (Natural Language Processing) pozwala na natychmiastowe podświetlenie stref ryzyka i wskazanie precyzyjnych numerów stron, co znacząco podnosi bezpieczeństwo prawne użytkowników.

2. Podstawy Teoretyczne

2.1. Metody NLP

W analizie tekstów prawnych wykorzystano podejście regułowe (**Rule-based NLP**), oparte na deterministycznych algorytmach i słownikach kontrolowanych. W przeciwieństwie do metod statystycznych (Machine Learning), podejście regułowe gwarantuje 100% powtarzalność wyników, precyzję semantyczną oraz brak błędów interpretacyjnych (*hallucinations*), co jest kluczowe w systemach LegalTech.

2.2. Koncepcja Pattern Matching

Język prawniczy (*legalese*) cechuje się wysokim stopniem formalizacji i powtarzalnością struktur syntaktycznych. Do ekstrakcji cech wykorzystano **wyrażenia regularne (RegEx)**. Metoda ta charakteryzuje się minimalnym kosztem obliczeniowym, błyskawicznym działaniem (rzędu milisekund) oraz niezależnością od zewnętrznych modeli wagowych.

2.3. Specyfika języka polskiego

Ze względu na fleksyjność języka polskiego (odmiana przez przypadki), w systemie zastosowano hybrydowe rozwiązanie:

1. **Słowniki rdzeni semantycznych (JSON):** Wychwytują warianty fleksyjne słów (np. *karę, karą*) bez uruchamiania ciężkich lematorów.
2. **Szablony RegEx:** Maski uwzględniające znaki diakrytyczne (ą, ę, ł, ó, ś, ż, ź) i opcjonalne spacje (np. Sp\.\s*z\s*o\.\s*o\.), co eliminuje błędy edytorskie w tekście umowy.

3. Opis środowiska i bibliotek

3.1. Środowisko Microsoft Visual Studio 2022

Projekt zaimplementowano w IDE **Visual Studio 2022** (Python 3.7). Środowisko zapewniło pełną izolację zależności za pomocą wbudowanego menedżera pakietów pip oraz umożliwiło precyzyjne debugowanie przepływu danych tekstowych.

3.2. Wykorzystane biblioteki

- **Streamlit (1.22.0):** Framework do renderowania reaktywnego interfejsu webowego (UI) bezpośrednio z poziomu języka Python.
- **PyMuPDF / fitz (1.19.0):** Wydajny silnik do segmentowej ekstrakcji tekstu z plików PDF в pamięci RAM.
- **Matplotlib:** Biblioteka do generowania wykresów statystycznych osadzanych w kontenerze Streamlit.

4. Architektura systemu

Aplikacja posiada architekturę modularną z zachowaniem zasady separacji odpowiedzialności.

4.1. Struktura plików projektu



4.2. Opis modułów

- `risk_patterns.json`**:** Baza danych (słownik markerów ryzyka) sklasyfikowana według polskiego prawa ochrony konsumenta. Zapisana w standardzie utf-8-sig (brak błędów BOM w Windows).
- `pdf_reader.py`**:** Pobiera strumień bajtów PDF i tworzy słownik mapujący surowy tekst do konkretnych numerów stron.

- `analyzer.py`**:** Realizuje zadania NER za pomocą RegEx (identyfikacja spółek, osób fizycznych po markerach *pomiędzy*, *reprezentowanym przez* oraz dat).
- `reporter.py`**:** Silnik analityczny. Implementuje **mechanizm deduplikacji** zdań (`seen = set()`), skraca cytaty do 150 znaków i wylicza liniowy ranking *Safety Score* (spadek o 5% za każde unikalne zagrożenie, min. 20%).
- `ContractAuditorPL.py`**:** Główny plik uruchomieniowy. Inicjalizuje webowy dashboard Streamlit, renderuje wykresy Matplotlib i zarządza pobieraniem raportu tekstowego.

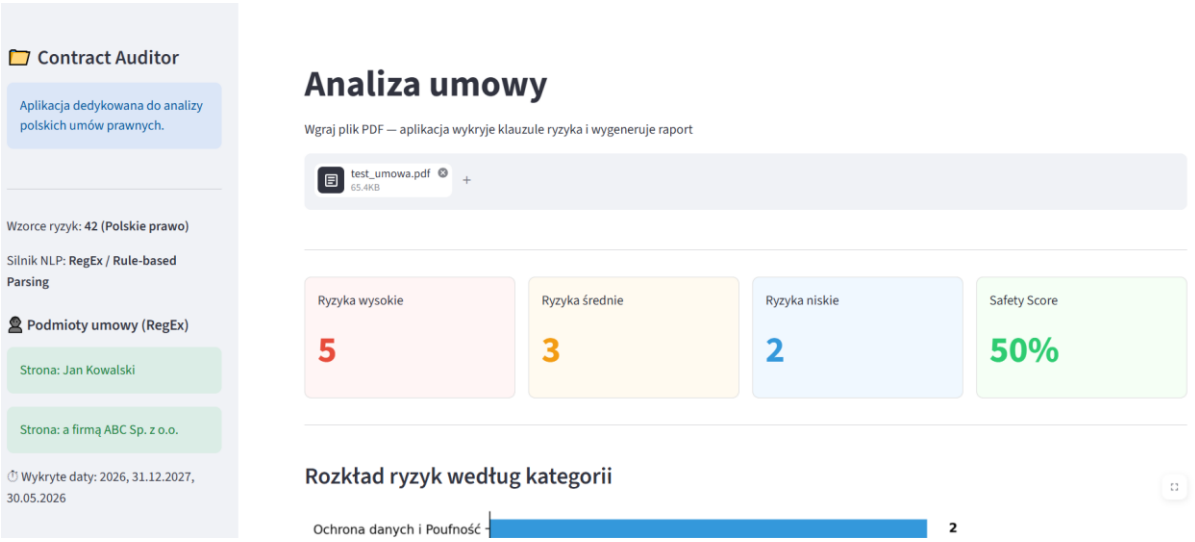
5. Prezentacja Wyników i Analiza Dashboardu

Wersja demonstracyjna aplikacji dostępna online pod adresem:

https://contract-auditor-pl.streamlit.app/

5.1. Graficzny interfejs użytkownika (UI/UX)

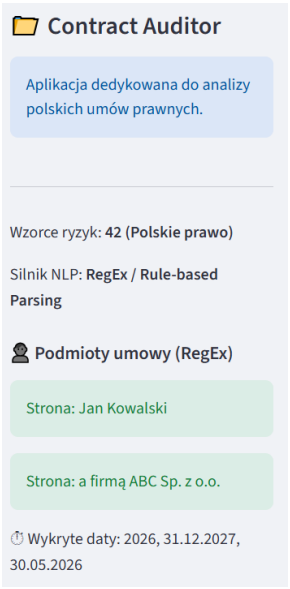
Warstwa prezentacji aplikacji została zaprojektowana w postaci jednostronicowego panelu analitycznego (Dashboardu), co zapewnia natychmiastowy wgląd w kondycję prawną dokumentu. Struktura interfejsu została przedstawiona na zrzucie ekranu głównego panelu (**Rysunek 1**).



Rysunek 1. Zrzut ekranu przedstawiający pełny panel analityczny aplikacji po załadowaniu dokumentu PDF.

Struktura interfejsu składa się z trzech głównych sekcji:

1. **Pasek boczny (Sidebar):** Prezentuje metadane techniczne aplikacji oraz wyniki modułu NER, czyli wykryte strony umowy i daty (**Rysunek 2**). To rozwiązanie skutecznie odciąża centralną część ekranu.



Rysunek 2. Zrzut ekranu przedstawiający boczny panel informacyjny (Sidebar) z wynikami działania modułu RegEx.

2. **Sekcja statystyk i wskaźników (Top Cards):** Cztery kolorowe kontenery HTML, które wizualizują ogólną liczbę zagrożeń w podziale na krytyczność oraz syntetyczną ocenę *Safety Score* (**Rysunek 3**).



Rysunek 3. Zrzut ekranu przedstawiający bloki statusowe oraz końcowy wskaźnik Safety Score.

3. **Sekcja dystrybucji i alertów (Main Content):** Zawiera dynamicznie generowany wykres słupkowy oraz listę rozwijanych bloków z precyzyjnie dopasowanymi cytatami z umowy (**Rysunek 4**).





Rysunek 4. Wykres słupkowy przedstawiający statystyczny rozkład wykrytych zagrożeń w umowie i lista rozwijanych bloków.

5.2. Wyjaśnienie kluczowych fragmentów kodu

W celu optymalizacji interfejsu i poprawy czytelności raportu, w module `reporter.py` zaimplementowano dwa mechanizmy: **deduplikację** oraz **kondensację kontekstową**. Kluczowy fragment kodu odpowiedzialny za tę operację przedstawiono na poniższym listingu (**Rysunek 5**).

```
display_text = sentence_clean[:150] + ("…" if len(sentence_clean) > 150 else "")

for category, markers in patterns.items():
    for marker in markers:
        if marker in sentence_lower:
            key = (page_num, sentence_clean[:80], category)
            if key in seen:
                break
            seen.add(key)
```

Rysunek 5. Fragment kodu źródłowego z pliku `reporter.py` implementujący algorytm deduplikacji i skrócenia tekstu.

Analiza kodu:

- **Kondensacja:** Zmienna `display_text` automatycznie przycina długie, wielolinijkowe zdania prawnicze do limitu 150 znaków, dodając elipsę (…). Zapobiega to zaburzeniom makiety interfejsu.
- **Deduplikacja:** Wykorzystanie unikalnego klucza tuple `key` oraz struktury zbioru `seen` gwarantuje, że jeśli ta sama klauzula powtórzy się w tekście,

system nie zaliczy jej ponownie. To chroni wskaźnik *Safety Score* przed błędnym zaniżaniem.

6. Analiza przypadków szczególnych (Walidacja na plikach PDF)

Poprawność działania algorytmów oraz elastyczność systemu została zweryfikowana na dwóch skrajnie różnych dokumentach testowych w formacie PDF. W celu przeprowadzenia kompleksowej walidacji i porównania wyników, dane analityczne z obu procesów zestawiono w zbiorczej tabeli (**Tabela 1**).

Cecha testowa	Dokument 1 (Najem lokalu)	Dokument 2 (Umowa B2B IT)
Nazwa pliku testowego	Umowa_Najmu_Rozszerzona.pdf	Umowa_B2B_Freelancer.pdf
Wykryte podmioty (RegEx)	Jan Kowalski, a firmą Vertex IT Sp. z o.o.	Adam Nowak, korporacyjnych firmy SoftTech S.A., r. pomiędzy firmą SoftTech S.A.
Ryzyka wysokie (Kary/Prawa)	**5**	**4**
Ryzyka średnie (Rozwiązanie)	**2**	**2**
Ryzyka niskie (RODO)	**2**	**4**
Wskaźnik Safety Score	**55%**	**50%**
Poprawność lokalizacji stron	100% (Strony: 1, 2, 3, 4)	100% (Strony: 1, 2, 3)

Tabela 1. Zbiorcze zestawienie wyników walidacji systemu.

6.1. Przypadek 1: Umowa Najmu Lokalu

Dokument ten reprezentował klasyczną umowę konsumencką. Aplikacja wykryła łącznie 9 unikalnych punktów ryzyka, co zgodnie z liniową heurystyką wagową dało wynik *Safety Score* на poziomie **55%**.

- **Działanie modułu NER:** System poprawnie zidentyfikował sygnatariuszy, wyciągając dane *Jan Kowalski* oraz strukturę korporacyjną *Vertex IT Sp. z o.o.*.
- **Analiza anomalii i ryzyk:** Wynik 5 ryzyk wysokich oraz 2 średnich wynika z faktu, że algorytm szczegółowo odseparował blisko położone znaczniki (np. *odsetki karne* i *karę umowną* na stronie 2 oraz *w trybie*

natychmiastowym i *skutkiem natychmiastowym* na stronie 4). Dowodzi to wysokiej czułości parsera regułowego. Pełny wykaz alertów z pozycjonowaniem przedstawia **Załącznik 1**.

6.2. Przypadek 2: Kontrakt B2B dla IT-Specjalisty

Dokument ten charakteryzował się specyficznym stylem redagowania usług programistycznych. System zidentyfikował 10 unikalnych zagrożeń, co obniżyło rating bezpieczeństwa dokumentu do **50%**.

- **Działanie modułu NER i analiza przesunięć kontekstowych:** W tym przypadku silnik RegEx wykrył postać *Adam Nowak*, ale ze względu na powtarzalność fraz wprowadzających w tekście, szablon `names_pattern` uchwycił również dodatkowe frazy: *korporacyjnych firmy SoftTech* S.A. oraz *r. pomiędzy firmą SoftTech S.A.*. Wynika to z faktu, że nazwa firmy pojawiała się w umowie w różnych konfiguracjach gramatycznych (zarówno w sekcji definicji stron, jak i w opisie standardów jakości kodu na stronie 3). Jest to klasyczny przykład nadmiarowości ekstrakcji (tzw. *over-triggering*), charakterystyczny dla systemów opartych na sztywnych regułach.
- **Analiza ryzyk:** Układ ryzyk (4 wysokie, 2 średnie, 4 niskie) idealnie odzwierciedla strukturę kontraktu B2B, gdzie nacisk położono na ochronę danych (RODO) oraz rygorystyczne kary za naruszenie poufności na stronie 2. Szczegółowy zrzut ekranu dla tego przypadku znajduje się w sekcji końcowej (**Załącznik 2**).

7. Wyzwania i Ograniczenia

Podczas realizacji projektu napotkano następujące problemy techniczne i strukturalne:

- **Izolacja środowiska (Python 3.7):** Ograniczenia starszej wersji interpretera uniemożliwiły bezproblemową kompilację nowoczesnych sieci neuronowych NLP (np. biblioteki spaCy). Wyzwaniem było stworzenie lekkiego silnika opartego na RegEx, który nie ustępuje dokładnością modelom statystycznym.
- **Konflikty kodowania znaków (UTF-8 BOM):** Środowisko Microsoft Visual Studio automatycznie dodaje ukryte nagłówki BOM do plików tekstowych w systemie Windows. Powodowało to błędy krytyczne parsera JSON. Problem rozwiązano przez zmianę trybu odczytu strumienia danych na utf-8-sig.
- **Segmentacja niestandardowych PDF:** Dokumenty posiadające nieregularny układ kolumn lub tabele mogą powodować zaburzenia w kolejności odczytu zdań przez silnik PyMuPDF.

8. Możliwe kierunki rozwoju systemu

- W kolejnym etapie rozwoju systemu planowane jest przejście z analizy regułowej na Deep NLP poprzez integrację polskiego lematyzatora statystycznego (np. spaCy pl_core_news_sm). Pozwoli to na sprowadzenie wszystkich odmienionych form czasowników i rzeczowników w umowie do ich leksemów bazowych, co rozszerzy zdolności detekcji ukrytych klauzul bez konieczności manualnego rozbudowywania słowników JSON.
- Implementacja biblioteki Tesseract OCR umożliwiłaby analizę umów w postaci skanów oraz zdjęć wykonanych aparatami smartfonów.
- Rozbudowa systemu o lekkie modele transformatorowe (np. Mini-BERT) w celu wykrywania zaawansowanych metafor prawnych i synonimów ukrytych klauzul.

9. Wnioski biznesowe

Zaprojektowana aplikacja posiada wysoki potencjał komercjalizacji w rosnącym sektorze LegalTech oraz Corporate Wellness:

- Narzędzie może być sprzedawane działom HR i logistyki do masowej, wstępnej weryfikacji umów z podwykonawcami, co redukuje koszty operacyjne firmy.
- Transformacja kodu w bota dla platform Slack lub Microsoft Teams, umożliwiającego szybki audyt dokumentów wewnątrz kanałów firmowych.
- Mobilny asystent prawny dla konsumentów (np. studentów wynajmujących mieszkania или freelancerów), oferujący darmowy podstawowy skan i płatny, szczegółowy raport PDF.

10. Podsumowanie

Projekt zintegrowanego systemu automatycznego audytu umów „Contract Auditor PL” zakończył się sukcesem implementacyjnym. Stworzone narzędzie w środowisku Microsoft Visual Studio stanowi realną odpowiedź na zapotrzebowanie rynkowe w obszarze technologii LegalTech. Modularna struktura kodu (podział na pdf_reader, analyzer, reporter) zapewniła wysoką przejrzystość architektury i elastyczność rozwoju. Zastosowanie metod parsowania regułowego połączonego z wyrażeniami regularnymi pozwoliło на uniezależnienie aplikacji od ciężkich modeli AI, gwarantując szybki czas reakcji oraz stabilność działania. Precyzyjne pozycjonowanie wykrytych klauzul abuzywnych na konkretnych stronach fizycznych dokumentu stanowi kluczową wartość inżynieryjną i użytkową całego systemu.

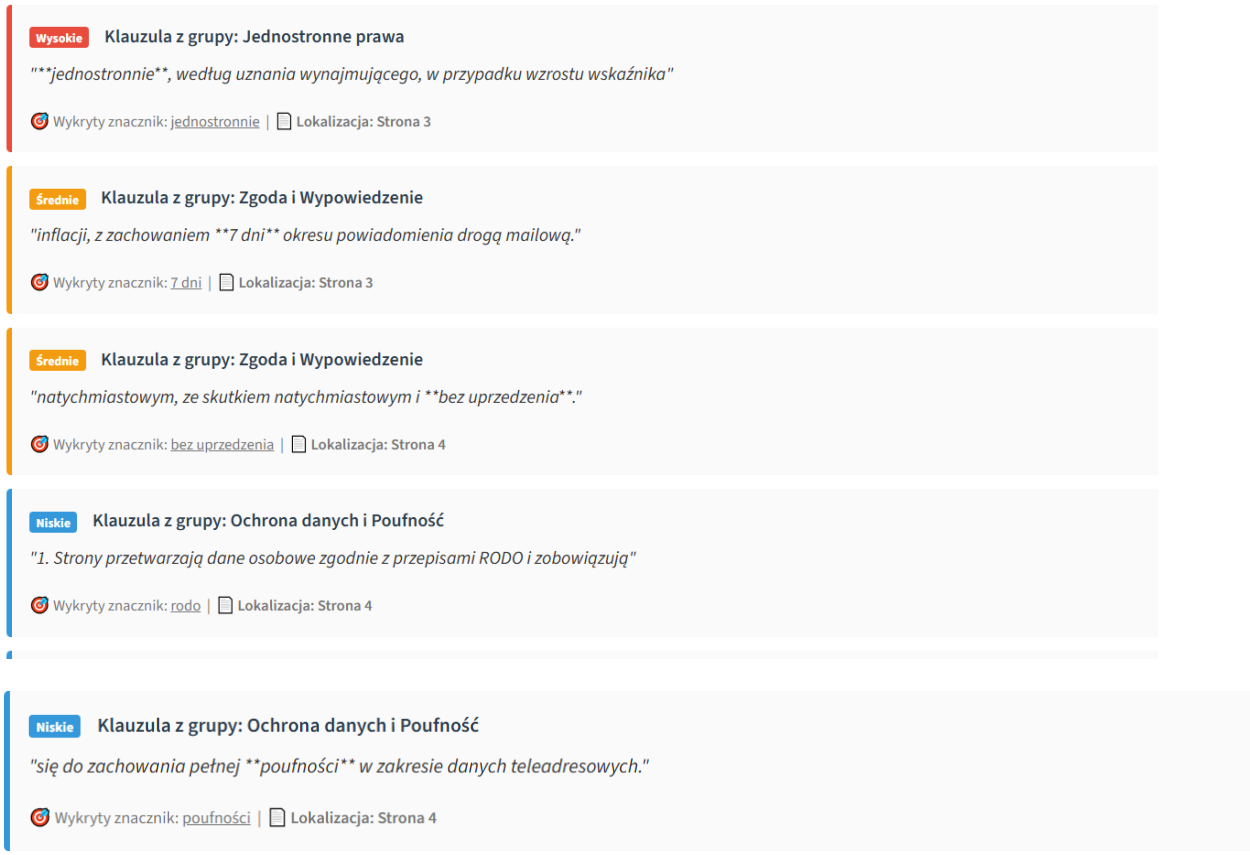
11. Załączniki

Załącznik 1. Wizualizacja alertów prawnych z przypisanym numerem strony dla dokumentu umowy najmu (Umowa_Najmu_Rozszerzona.pdf).

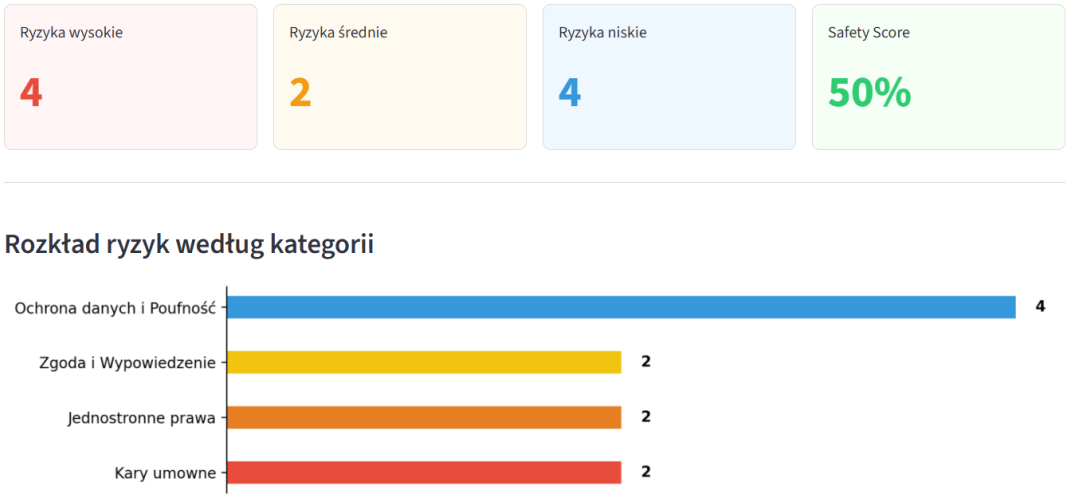








Załącznik 2. Zrzut ekranu przedstawiający sekcję raportu końcowego z podświetlonymi klauzulami dla kontraktu B2B IT (Umowa_B2B_Freelancer.pdf).



Wykryte klauzule ryzyka

Wysokie **Klauzula z grupy: Kary umowne**

*"poufne. Za każdy przypadek naruszenia poufności Zleceniobiorca **zapłaci karę**"*

Wykryty znacznik: zapłaci karę | **Lokalizacja: Strona 2**

Wysokie **Klauzula z grupy: Kary umowne**

*"Zleceniodawca naliczy **odsetki karne** oraz zastrzega sobie prawo do nałożenia kary"*

Wykryty znacznik: odsetki karne | **Lokalizacja: Strona 2**

Wysokie **Klauzula z grupy: Jednostronne prawa**

*"1. Zleceniodawca **zastrzega sobie prawo do zmiany** zakresu wymagań"*

Wykryty znacznik: zastrzega sobie prawo do zmiany | **Lokalizacja: Strona 3**

Wysokie **Klauzula z grupy: Jednostronne prawa**

*"funkcjonalnych **jednostronnie**, według uznania wynajmującego, bez wpływu na"*

Wykryty znacznik: jednostronnie | **Lokalizacja: Strona 3**

Średnie **Klauzula z grupy: Zgoda i Wypowiedzenie**

*"2. Zleceniodawca może wypowiedzieć umowę **w trybie natychmiastowym**, ze"*

Wykryty znacznik: w trybie natychmiastowym | **Lokalizacja: Strona 3**

Średnie **Klauzula z grupy: Zgoda i Wypowiedzenie**

*"**skutkiem natychmiastowym**, jeśli uzna, że jakość kodu nie spełnia standardów"*

Wykryty znacznik: skutkiem natychmiastowym | **Lokalizacja: Strona 3**

Niskie **Klauzula z grupy: Ochrona danych i Poufność**

*"§ 2. Odpowiedzialność finansowa i zabezpieczenie **poufności**"*

Wykryty znacznik: poufności | **Lokalizacja: Strona 2**

Niskie **Klauzula z grupy: Ochrona danych i Poufność**

*"poufne. Za każdy przypadek naruszenia **poufności** Zleceniobiorca zapłaci karę"*

Wykryty znacznik: poufności | **Lokalizacja: Strona 2**

Niskie **Klauzula z grupy: Ochrona danych i Poufność**

"§ 4. Dane osobowe"

Wykryty znacznik: dane osobowe | **Lokalizacja: Strona 3**

Niskie **Klauzula z grupy: Ochrona danych i Poufność**

"wytycznych RODO."

Wykryty znacznik: rodo | **Lokalizacja: Strona 3**